

# Markov Chain MonteCarlo

Marcos Mobbili

Carolina Daza

# Resumen

Markov chain Montecarlo (MCMC) es una técnica que permite hacer un muestreo eficiente de datos de funciones de probabilidad complicadas.

Aplicado a inferencia bayesiana ayuda a estimar la probabilidad a posteriori cuando no se puede calcular analíticamente su distribución.

## Algunos conceptos

**1**

Muestreo, aceptación/rechazo  
Propiedades de Cadenas de Markov  
Markov Chain Montecarlo  
Algoritmo de Metropolis-Hastings  
Enfoque bayesiano

**2**

## Ejemplo práctico

## **Aproximar**

Estimar esperanzas de funciones complicadas  
Inferencia de posteriors

## **Visualización**

Es mas fácil la interpretación del proceso y que calcular directamente las probabilidades o aproximarlas

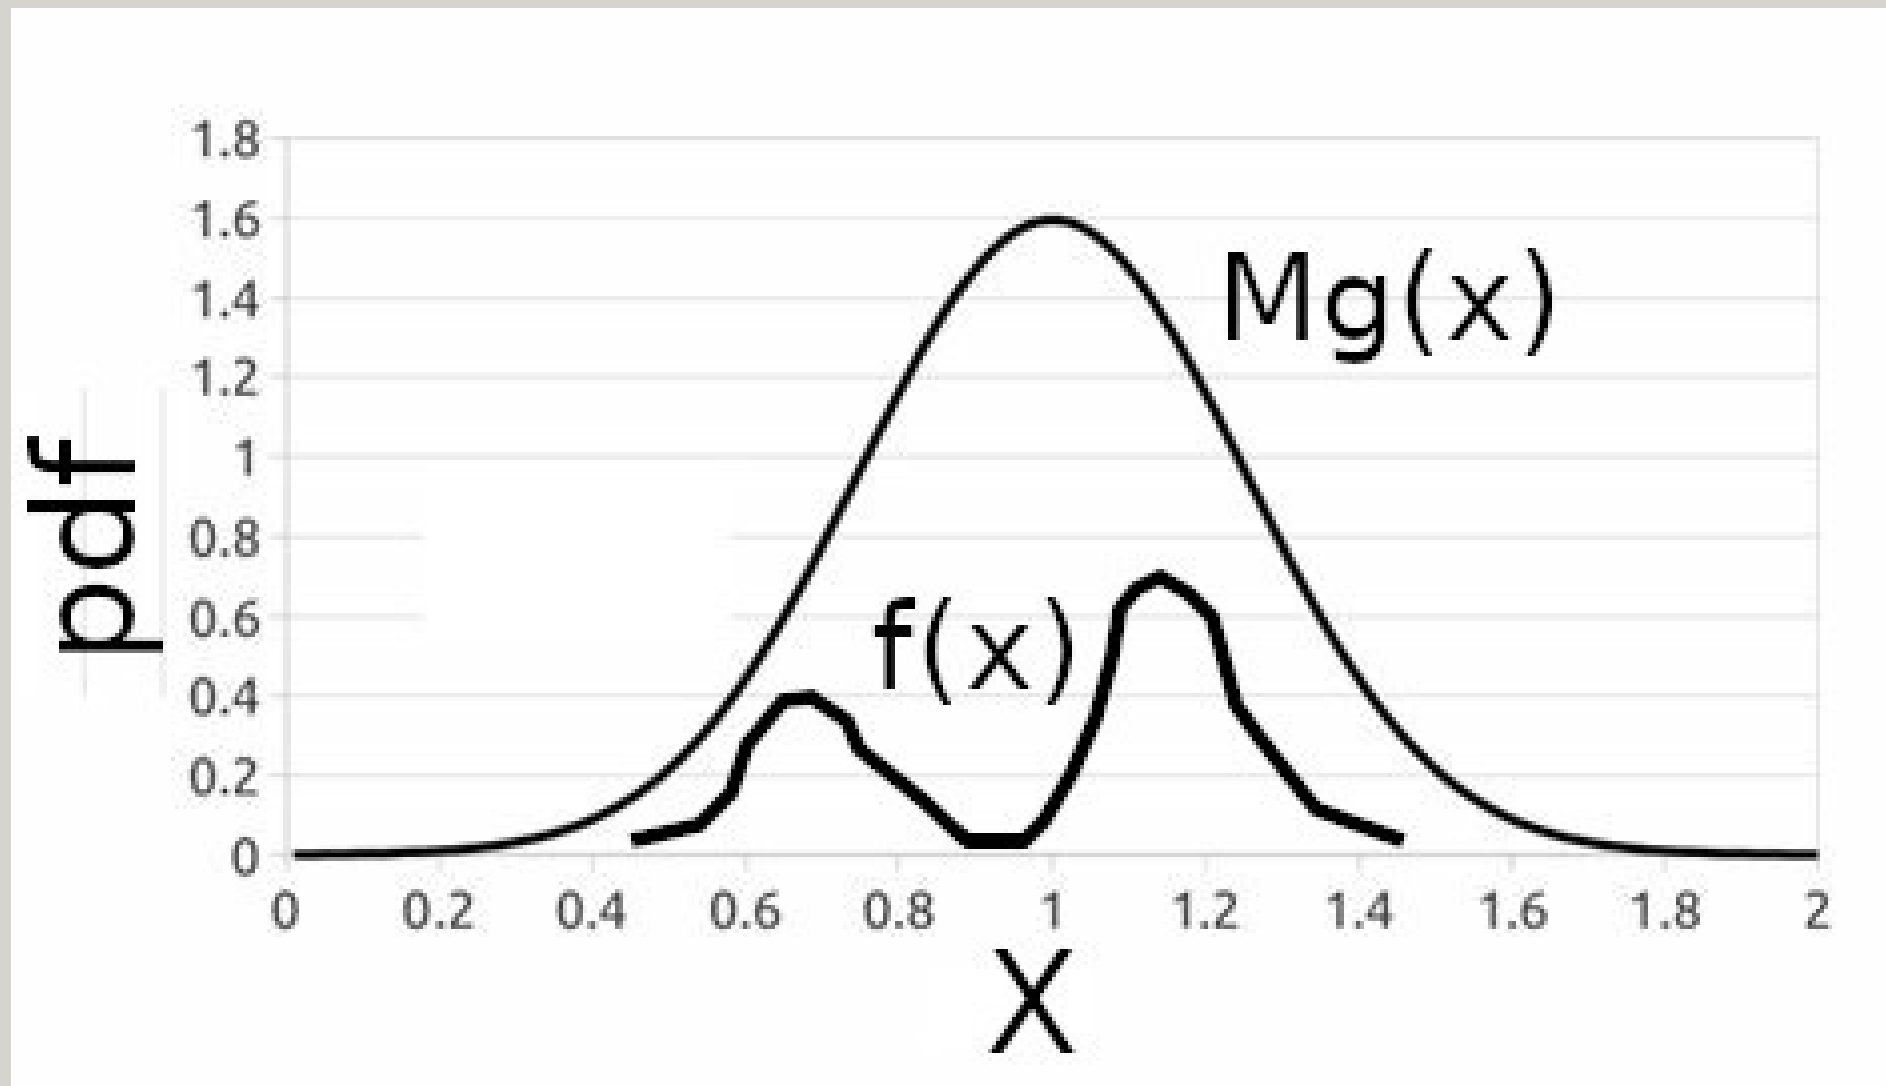
## **Es de uso general**

Es aplicable a problemas de variada índole

# **¿Para que muestrear?**

# Aceptación/Rechazo

Queremos muestrear de  $p(x) \propto f(x)$ , buscamos una función que cubra a  $f$   
La candidata es una normal escaleada por un número  $M$



## Proceso

Se samplea una muestra de  $g$

Se acepta con probabilidad  
 $f(s)/Mg(s)$


## Intuición

Si el cociente es grande, la muestra es muy probable en  $f(x)$  y menos en  $g(x)$ , entonces la tomo porque es de alta probabilidad y rara

# Aceptación/Rechazo

Queremos muestrear de  $p(x) \propto f(x)$

La candidata es una normal escaleada por un número  $M$



## Proceso

Se samplea una muestra de  $g$

Se acepta con probabilidad  
 $f(s)/Mg(s)$

## Intuición

Si el cociente es grande, la muestra es muy probable en  $f(x)$  y menos en  $g(x)$ , entonces la tomo porque es de alta probabilidad y rara





# Objetivo

Muestrear de una distribución de probabilidad  $p$ , que puede tener una forma muy complicada, o aproximar  $E[f(x)]$

# Intuición

Se comienza en algún punto del espacio y nos vamos moviendo hacia una región donde la probabilidad de esa distribución es alta y se trata de mantenerse en esa región

# Propiedades de las cadenas de Markov

La propiedad principal es que un estado depende solamente del estado anterior:

$$\begin{aligned} P(X_{n+1} = x_{n+1} | X_0 = x_0, X_1 = x_1, \dots, X_n = x_n) \\ = P(X_{n+1} = x_{n+1} | X_n = x_n) \end{aligned}$$

## Estacionaridad

Bajo supuestos de aperiodicidad e irreducibilidad, las probabilidades marginales de los estados tienden a un estacionario:

$$\pi T = \pi$$

Una cadena que cumple estas propiedades se dice *Ergódica*

## Ecuación de Chapman-Kolmogorov

La probabilidad de ir en  $n$  pasos de un estado  $i$  a uno  $j$  si la cadena es homogénea es:

$$p_{i,j}(n) = T_{i,j}^n$$

y no depende del estado inicial

## Reversibilidad (Balance Detallado)

Si  $\pi$  cumple esta propiedad,  $\pi$  es una distribución estacionaria con matriz de transición  $T$ :

$$\pi_a T_{ab} = \pi_b T_{ba} \quad \forall a, b \in \Pi$$



# Markov Chain MonteCarlo

## Markov + MonteCarlo

Usamos las propiedades de la cadena para estimar/aproximar empíricamente una función

## Proceso



Se toma un estado inicial

Se aplica muchas veces la matriz de transición  $T$  (o una función de transición  $g$ )

Los estados obtenidos van a converger a una distribución de probabilidad en el estacionario que se aproxima al valor esperado de la función real o a la distribución real

## ¿Como se calcula?

Algoritmos de aceptación/rechazo como el de Metropolis/Metropolis-Hastings (1953)





# Algoritmo de Metrópolis-Hastings

## Paso 0

Sugerir una función de transición de los estados, por ejemplo una normal

$$g(x_{t+1}|x_t) = \mathcal{N}(x_t, \sigma^2)$$

## Paso 1

Se muestrea un estado inicial con esta distribución

$$x_{t+1}^* = x_t + \mathcal{N}(x_t, \sigma^2)$$

## Paso 2

Se calcula la probabilidad de aceptación  $A$  de la muestra

$$\frac{A(t \rightarrow t+1)}{A(t+1 \rightarrow t)} = \frac{f(x_{t+1}^*)g(x_t|x_{t+1}^*)}{f(x_t)g(x_{t+1}^*|x_t)}$$

## Paso 3

Si la probabilidad es mayor que 1 me quedo la muestra, si no lanzo un numero aleatorio y dependiendo de su valor, acepto si esta probabilidad es mayor que  $A$

esta es casi una

**POSTERIOR**

# Enfoque Bayesiano

## Paso 0

Sugerir una función de transición de los estados, por ejemplo una normal

## Paso 1

Se muestrea un estado inicial con esta distribución

## Paso 2

Se calcula la probabilidad de aceptación  $A$  de la muestra

## Paso 3

Si la probabilidad es mayor que 1 me quedo la muestra, si no lanzo un numero aleatorio y dependiendo de su valor, acepto si esta probabilidad es mayor que  $A$

$$\theta : \theta_0, \theta_1 \dots \theta_n$$

$$p(\theta|\mathcal{D}) = \frac{p(\mathcal{D}|\theta)p(\theta)}{p(\mathcal{D})}$$

$$A(t \rightarrow t^*) = \min \left\{ 1, \frac{p(\theta_t^*|\mathcal{D})q(\theta_t^*, \theta_t)}{p(\theta_t|\mathcal{D})q(\theta_t, \theta_t^*)} \right\}$$

Likelihood

$$A(t \rightarrow t^*) = \min \left\{ 1, \frac{p(\mathcal{D}|\theta_t^*)p(\theta_t^*)q(\theta_t^*, \theta_t)}{p(\mathcal{D}|\theta_t)p(\theta_t)q(\theta_t, \theta_t^*)} \right\}$$

prior

$$r = p_c^*/p_0 > 1 \quad \theta_t = \theta_c$$

$$r = p_c^*/p_0 < 1$$

$$\text{si } \mathcal{U}(0,1) > r \quad \theta_t = \theta_c$$

$$\text{si } \mathcal{U}(0,1) < r \quad \theta_t = \theta_0$$

# Referencias

## Excelentes canales de matemáticos y varios

ritvikmath channel

<https://www.youtube.com/channel/UCUcpVoi5KkJmnE3bvEhHR0Q>

mathematicalmonk channel

[https://www.youtube.com/channel/UCcAtD\\_VYwcYwVbTdvArsm7w](https://www.youtube.com/channel/UCcAtD_VYwcYwVbTdvArsm7w)

Normalized Nerd channel

<https://www.youtube.com/channel/UC7Fs-Fdpe0I8GYg3lboEuXw>

Introduction to Bayesian statistics, part 2: MCMC and the Metropolis–Hastings algorithm, StataCorp LLC  
<https://www.youtube.com/watch?v=OTO1DygELpY>

Videos MCMC, Andres Farall

<https://www.youtube.com/watch?v=6eCdiJ07uuE&t=327s>

Bayesian Modeling with R and Stan (Reupload),  
Salt Lake City R Users Group

<https://www.youtube.com/watch?v=QqwCqPYbatA>

MCMC in R

<https://www.youtube.com/watch?v=AT49XR3G38w>

A Markov chain Monte Carlo example in astronomy

<http://personal.psu.edu/muh10/MCMCtut/MCMC.html>

Penn State Astrostatistics MCMC tutorial Murali Haran. Penn State Dept. of Statistics

<http://personal.psu.edu/muh10/MCMCtut/chptmodel2021.pdf>